
Università degli Studi di Salerno

.DIEM

Dipartimento di Ingegneria dell'Informazione ed Elettrica e Matematica Applicata

Corso di Laurea Magistrale in Ingegneria Informatica
**Curriculum di Enterprise Software Architectures**

# Data Management Systems

Project Work

## Twitter Sentiment Analysis

Grazia Ferrara **0622701901**

**Anno accademico 2023-2024**

## Sommario

# 1. Descrizione della realtà di interesse

Titolo: **Twitter Sentiment Analysis**

*Un tweet è un messaggio di testo avente una lunghezza non superiore a 4000 caratteri, inviato a un sito Internet tramite instant messenger, e-mail o cellulare con lo scopo di comunicare informazioni in tempo reale. I tweet consentono agli utenti di mettere in piedi delle vere e proprie discussioni in merito ad un determinato argomento, legandosi a quest'ultimo per mezzo di un hashtag o semplicemente sulla base di parole ricorrenti. Hashtag e parole ricorrenti concorrono infatti alla creazione di un trend. I trend sono mostrati nella home page di Twitter e sono facilmente accessibili agli utenti in modo tale che possano avere un'idea degli argomenti più in voga del momento non appena effettuano l'accesso. Gli utenti possono vedere i tweet di altri utenti, se pubblici o se presenti nella loro rete di amicizie, mettere like e condividerli nella propria bacheca ("re-postarli" in gergo). Utilizzando i tweet che sono legati ad un determinato topic, si può effettuare la sentiment analysis e vedere qual è l'opinione espressa dalle persone tramite i tweet su un determinato argomento (positiva, negativa, neutra), utilizzando qualche tool che, preso in input il testo, restituisce il sentiment. È di interesse lo studio del sentiment in vari ambiti applicativi.*
*Si intende progettare e realizzare una base di dati non relazionale (non avendo i dati a disposizione uno schema fisso e ben definito) per la memorizzazione delle informazioni necessarie ad effettuare la sentiment analysis sui tweet legati a un certo topic, considerando i seguenti elementi:*

1. *Con riferimento ai tweet sono essenziali le seguenti informazioni (basilari ma non esaustive): username dell'utente che ha pubblicato il tweet, testo del tweet, topic del tweet, il sentiment ad esso associato.*
2. *Con riferimento agli utenti sono essenziali le seguenti informazioni (basilari ma non esaustive): username dell'utente, numero di persone seguite, numero di persone che lo seguono e se è verificato.*
3. *Con riferimento ai trend sono essenziali le seguenti informazioni (basilari ma non esaustive): nome del trend, numero di post pubblicati per quel trend e il luogo e la data in cui esso è andato virale.*
4. *È di interesse conoscere il sentiment delle persone per un dato trend.*
5. *È di interesse misurare l'impatto sociale di un trend in termini di persone presumibilmente raggiunte all'interno della rete sociale di Twitter.*
6. *È di interesse misurare il grado di affidabilità dell'utente nell'espressione di un certo sentiment per un dato trend.*
7. *È di interesse studiare la sentiment history di un utente.*
8. *È di interesse calcolare le metriche di engagement.*

## 1.1. Analisi della realtà di interesse

Dalla descrizione fornita, è possibile identificare una serie di elementi chiave relativi alla realtà di interesse:

1. ***Tweet***: Sono brevi messaggi di testo con una lunghezza massima di 4000 caratteri inviati attraverso diverse piattaforme, come instant messenger, e-mail o dispositivi mobili. Questi messaggi servono a comunicare informazioni in tempo reale.

2. ***Trend***: Sono utilizzati per collegare i tweet a determinati argomenti e contribuiscono alla creazione dei trend. I trend rappresentano gli argomenti più popolari e sono facilmente accessibili agli utenti nella home page di Twitter.

3. ***Sentiment analysis***: Viene utilizzata per valutare l'opinione espressa nelle discussioni online relative a un determinato argomento. Questa analisi può determinare se il sentimento è positivo, negativo, neutro o altro, attraverso l'uso di strumenti specifici.

4. ***Informazioni chiave necessarie***:
    - Per i tweet: username dell'utente, testo del tweet, topic del tweet, sentiment associato.
    - Per gli utenti: username, numero di seguaci, numero di persone seguite, verifica del profilo.
    - Per i trend: nome del trend, numero di post associati, luogo e data di diffusione.

5. ***Obiettivi specifici***:
    - Conoscere il numero di persone che esprimono un determinato tipo di sentiment su un topic.
    - Misurare l'impatto di un tweet con un dato sentiment sulla rete, in base alla rilevanza sociale dell'utente che l'ha pubblicato.
    - Identificare utenti che hanno pubblicato più tweet su un topic con sentiment discordanti che potrebbero influire negativamente sull'analisi.
    - Studiare come evolve l'espressione del sentiment di un utente nel tempo.
    - Ottenere le metriche di engagement: condivisioni, citazioni, like, …

In sintesi, il progetto mira a condurre un'analisi approfondita dei sentiment legati ai trending topics, considerando la rilevanza sociale degli utenti, la coerenza dei sentiment e l'effettivo impatto delle discussioni online. Questi elementi contribuiranno a una comprensione più completa di come le discussioni influenzino l'opinione pubblica e saranno fondamentali per valutare l'efficacia delle campagne di comunicazione e il coinvolgimento degli utenti nelle discussioni online.

# 2. Analisi delle specifiche

## 2.1. Glossario dei termini

| | Termine | Descrizione | Sinonimi | Collegamenti |
|---|---|---|---|---|
| **1** | Tweet | Messaggio o post breve pubblicato su Twitter, contenente testo, immagini o video. | Post, messaggio, aggiornamento di stato | Utente, Trend |
| **2** | Trend | Temi o discussioni più rilevanti e attuali all'interno della comunità online in un dato momento. | Tendenza, moda, argomento popolare | Tweet |
| **3** | Utente | Individuo che utilizza una piattaforma di social media, come Twitter. Può pubblicare tweet, seguire altri utenti ed essere seguito da altri. | Account, profilo, persona registrata | Tweet |
| **4** | Sentiment | Opinione associata a un determinato argomento, tweet o discussione online. | Opinione | Tweet, Utente |
| **5** | Sentiment Analysis | Processo di analisi del testo mirato a determinare l'opinione associata a un contenuto online. | Analisi dell'opinione | Tweet, Utente, Trend |
| **6** | Social influence | Effetto che un utente o un contenuto online ha sulla sua cerchia di seguaci e sull'opinione pubblica. | Potere di persuasione | Utente, Sentiment Analysis |
| **7** | Agreement | Misura in cui gli utenti online esprimono sentimenti simili o discordanti su un determinato argomento. | Concordanza, accordo, consenso, armonia | Sentiment analysis, Utente |

*Tabella 1. Glossario dei Termini*

## 2.2. Strutturazione dei requisiti in frasi

### 2.2.1. **Frasi di carattere generale**

*Si intende progettare e realizzare una base di dati non relazionale (non avendo i dati a disposizione uno schema fisso e ben definito) per la memorizzazione delle informazioni necessarie ad effettuare la sentiment analysis sui tweet legati a un certo topic.*

### 2.2.2. **Frasi relative a Tweet**

*Un tweet è un messaggio di testo avente una lunghezza non superiore a 4000 caratteri, inviato a un sito Internet tramite instant messenger, e-mail o cellulare con lo scopo di comunicare*

*informazioni in tempo reale. I tweet consentono agli utenti di mettere in piedi delle vere e proprie discussioni in merito ad un determinato argomento, legandosi a quest'ultimo per mezzo di un hashtag o semplicemente sulla base di parole ricorrenti.*
*Con riferimento ai tweet sono essenziali le seguenti informazioni (basilari ma non esaustive): username dell'utente che ha pubblicato il tweet, testo del tweet, topic del tweet, , il sentiment ad esso associato.*

#### 2.2.3. **Frasi relative a Trend**

*Hashtag e parole ricorrenti concorrono infatti alla creazione di un trend. I trend sono mostrati nella home page di Twitter e sono facilmente accessibili agli utenti in modo tale che possano avere un'idea degli argomenti più in voga del momento non appena effettuano l'accesso.*
*Con riferimento ai trend sono essenziali le seguenti informazioni (basilari ma non esaustive): nome del trend, numero di post pubblicati per quel trend e il luogo e la data in cui esso è andato virale.*

#### 2.2.4. **Frasi relative a Utente**

*Gli utenti possono vedere i tweet di altri utenti, se pubblici o se presenti nella loro rete di amicizie, mettere like e condividerli nella propria bacheca ("re-postarli" in gergo).*
*Con riferimento agli utenti sono essenziali le seguenti informazioni (basilari ma non esaustive): username dell'utente, numero di persone seguite, numero di persone che lo seguono e se è verificato.*

#### 2.2.5. **Frasi relative a Sentiment Analysis**

*È di interesse lo studio del sentiment in vari ambiti applicativi. Utilizzando i tweet che sono legati ad un determinato topic, si può effettuare la sentiment analysis e vedere qual è l'opinione espressa dalle persone tramite i tweet su un determinato argomento (positiva, negativa, neutra), utilizzando qualche tool che, preso in input il testo, restituisce il sentiment.*

#### 2.2.6. **Frasi relative a tipi specifici di Analisi**

*È di interesse conoscere il sentiment delle persone per un dato trend.*
*È di interesse misurare l'impatto sociale di un trend in termini di persone presumibilmente raggiunte all'interno della rete sociale di Twitter.*
*È di interesse misurare il grado di affidabilità dell'utente nell'espressione di un certo sentiment per un dato trend.*
*È di interesse studiare la sentiment history di un utente.*
*È di interesse calcolare le metriche di engagement.*

### 2.3. Identificazione delle operazioni principali

Di seguito vengono riportate solo le operazioni più complesse
**Operazione 1:** *per ogni trend, selezionare tutti i tweet associati al trend e mostrare il sentiment ottenuto come media dei sentiment dei tweet selezionati (20 volte al giorno)*
**Operazione 2:** *per ogni trend, selezionare tutti i tweet che vi afferiscono e, per ogni categoria di sentiment che il tweet può assumere, stampare la percentuale di tweet che hanno ottenuto quel determinato sentiment (20 volte al giorno)*
**Operazione 3:** *dato un certo trend, identificare tutti gli utenti che hanno pubblicato tweet che vi afferiscono e sulla base del loro numero di followers identificare quante persone sono state all'incirca raggiunte dal trend per ognuno di quei tweet, come somma del numero di followers (20 volte al giorno)*

**Operazione 4:** *per ogni utente, raggruppare i tweet che ha scritto per topic e, per ogni cluster, assegnare all'utente un punteggio di coerenza, fare la media dei punteggi ottenuti (1 volta a settimana)*

**Operazione 5:** *dato un utente, prendi i tweet che ha scritto e calcola le percentuali di tweet con sentiment positivo, negativo e neutro (1 volta a settimana)*

**Operazione 6:** *per ogni trend calcolare il numero medio di like, condivisioni, retweet e commenti che i suoi post hanno avuto (1 volta al mese)*

**Operazione 7:** *dato un trend, per ogni tweet ad esso associato, verificare se i suoi commenti hanno dato origine a una discussione identificando eventuali sentiment discordanti (600 volte al mese)*

# 3. Progettazione Concettuale

## 3.1. Schema Concettuale

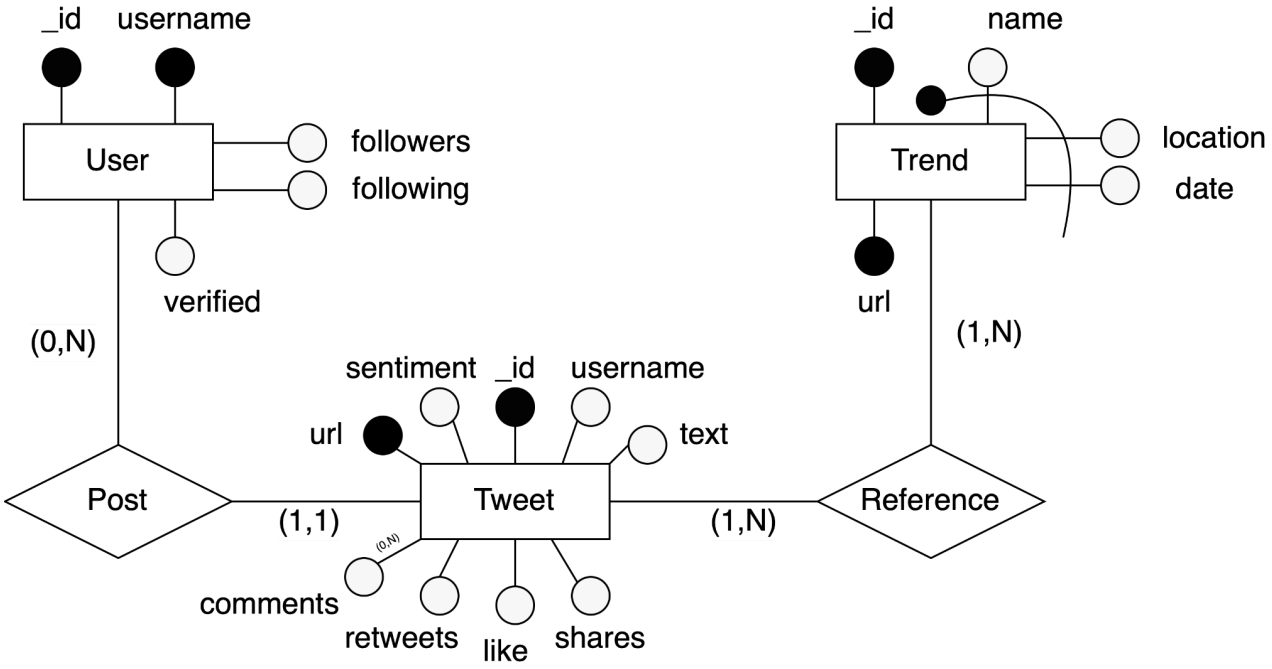


### 3.1.1. **Note sullo schema E-R**

*Per la progettazione è stata utilizzata una strategia di tipo top-down. In particolare si sono prima individuate le entità e le associazioni e poi sono stati aggiunti gli attributi. Lo schema ER qui riportato non è esaustivo (ad esempio per le entità non sono stati inseriti tutti i possibili attributi), proprio perché essendo in un contesto web ed avendo a che fare con una base di dati non relazionale, non si ha un insieme finito e limitato di dati di interesse.*

## 3.2. Dizionario dei Dati

| Entità | Descrizione | Attributi | Identificatore |
|---|---|---|---|
| Tweet | Messaggio o post breve pubblicato su Twitter, contenente testo, immagini o video. | _id, url, username, text, comments (multivalore e opzionale), retweets, like, shares, sentiment | _id, url |
| Trend | Tema rilevante in una comunità in un determinato momento. | _id, url, name, location, date | _id, url, (name, location, date) |
| User | Utente social che ha la facoltà di pubblicare tweet ed | _id, username, followers, following, verified | _id, username |

| | | | |
|---|---|---|---|
| | interagire con i post altrui. | | |

*Tabella 2. Dizionario dei dati – Entità*

| Relazioni | Descrizione | Entità Coinvolte | Attributi |
|---|---|---|---|
| Post | Pubblicazione di un tweet da parte di un utente. | User, Tweet | - |
| Reference | Appartenenza dell'argomento di un tweet ad un trend. | Trend, Tweet | - |

*Tabella 3. Dizionario dei dati - Relazioni*

## 3.3. Regole Aziendali

| Regole di Vincolo |
|---|
| **(RV1)** L'attributo *verified* di *User* può assumere i valori *true* o *false*. |
| **(RV2)** L'attributo *following* di *User* deve essere sempre maggiore o uguale di zero. |
| **(RV3)** L'attributo *followers* di *User* deve essere sempre maggiore o uguale di zero. |
| **(RV4)** L'attributo *date* di *Trend* deve avere una data non successiva alla data odierna. |

*Tabella 4. Regole di vincolo*

# 4. Progettazione Logica

## 4.1. Analisi dello Schema Concettuale

### 4.1.1. Analisi delle Prestazioni

#### *4.1.1.1. Tavola dei volumi*

| Concetto | Tipo | Volume |
|---|---|---|
| Trends | E | 100 |
| Tweets | E | 10000 |
| Users | E | 3000 |
| Post | R | 10000 |
| Reference | R | 10000 |

*Tabella 6. Tavola dei volumi*

#### *4.1.1.2. Tavola delle operazioni*

| Operazione | Tipo | Frequenza |
|---|---|---|
| Operazione 1: *Sentiment medio di un trend* | B | 20 al giorno |
| Operazione 2: *Sentiment percentuali di un trend* | B | 20 al giorno |
| Operazione 3: *Grado di diffusione di un trend* | I | 20 al giorno |
| Operazione 4: *Grado di affidabilità di un utente su un trend* | B | 1 volta alla settimana |
| Operazione 5: *Sentiment percentuali di un utente* | I | 1 volta alla settimana |
| Operazione 6: *Calcolo delle metriche di engagement* | B | 1 volta al mese |
| Operazione 7: *Rilevazione di discussioni* | I | 600 volte al mese |

*Tabella 7. Tavola delle operazioni*

## 4.2. Scelta degli identificatori principali

*Per identificare il Tweet si è scelto di utilizzare, tra gli attributi presenti, il suo url, e lo stesso vale per il Trend. Il Trend però, può anche essere identificato tramite il suo nome, la data ed il luogo in cui si è diffuso. L'utente può essere invece identificato univocamente tramite il suo username. Considerando la base di dati che verrà utilizzata successivamente, possiamo aspettarci però che ognuno di essi abbia un _id univoco (ObjectId), che verrà usato per semplicità come identificatore principale in ciascuno dei casi.*

## 4.3. Scelta degli indici

Gli indici in MongoDB supportano l'esecuzione di query in maniera efficiente, in modo da evitare di scansionare tutti i documenti di un database per restituire dei risultati. Dal momento in cui sono anche costosi perché devono essere aggiornati ad ogni operazione di scrittura, è bene metterli solo su campi che vengono usati molto di frequente per effettuare delle ricerche. Si è pensato che sarebbe una buona idea quella di indicizzare gli ***username*** degli utenti e creare un ulteriore indice, stavolta *composto*, su ***data***, ***luogo*** e ***nome*** di un trend.

## 4.4. Schema logico

*Poiché in MongoDB le operazioni di write vengono fatte in maniera atomica, per la rappresentazione dei commenti dei tweet, si è deciso di usare un modello di dati denormalizzato, attraverso **documenti embedded**. Come suggerisce la documentazione di MongoDB, questo tipo di rappresentazione è adatta a rappresentare relazioni di 'contains' e in questo modo, usando un'unica operazione atomica, è possibile effettuare l'aggiornamento sia di un attributo del tweet, che dei tweet presenti nell'array* comments *dei commenti. Ad esempio, è possibile rimuovere un tweet dai commenti ad aggiornare il numero delle risposte nel tweet principale con un'unica operazione di write. Inoltre, tale disposizione dei documenti torna utile per velocizzare le operazioni di lettura quando dal tweet 'parent' si ha bisogno di accedere ai tweet 'children'.*

*Per modellare la relazione uno a molti che sussiste tra User e Tweet, si è deciso di usare un modello di dati normalizzato, usando dei **references** tra i documenti. Tale scelta è dovuta al fatto che la disposizione embedded dell'utente all'interno del tweet avrebbe provocato una forte duplicazione dei dati dello stesso, dal momento in cui è plausibile che l'utente possa scrivere più tweet per un determinato topic, oppure scrivere un tweet e rispondere ai commenti sotto il suo post. Pertanto i documenti della collezione User, avranno al loro interno un array di reference* tweets *ai documenti della collezione Tweet ed i documenti della collezione Tweet avranno un campo* user_id *che conterrà il reference al documento che rappresenta l'utente che ha scritto quel tweet nella collezione User.*

*Per modellare la relazione molti a molti che sussiste tra Trend e Tweet, si è deciso di usare un modello di dati normalizzato, usando dei **references** tra i documenti. Trattandosi di una relazione di questo tipo, non è conveniente usare la rappresentazione tramite documenti embedded che provocherebbe una ingente duplicazione di tutti i dati. Pertanto i documenti della collezione Trend avranno un array di riferimenti* tweets *ai Tweet che sono stati pubblicati in merito a quello specifico trend, mentre i documenti della collezione Tweet avranno un array di riferimenti* trends *ai trend a cui afferiscono.*

*Dunque*

- *i **Tweet** saranno modellati nel seguente modo*

```
{
        _id: <ObjectId>,
        url: <String>,
        username: <String>,
```

*user_id : <ObjectId>,*
*text: <String>,*
*comments: [{tweetDocument},...,{tweetDocument}],*
*retweets: <Int32>,*
*like: <Int32>,*
*shares: <Int32>,*
*sentiment: <Double>,*
*trends: [<ObjectId>,...,<ObjectId>]*
*}*

- *i **Trend** saranno modellati nel seguente modo*

*{*
*_id: <ObjectId>,*
*url: <String>,*
*name: <String>,*
*location: <String>,*
*date: <Timestamp>,*
*tweets: [<ObjectId>,...,<ObjectId>]*
*}*

- *gli **User** saranno modellati nel seguente modo*

*{*
*_id: <ObjectId>,*
*username: <String>,*
*followers: <Int32>,*
*following: <Int32>,*
*verified: <Boolean>,*
*tweets: [<ObjectId>,...,<ObjectId>]*
*}*

*Eventuali ulteriori attributi nei documenti sono contemplati per la natura stessa della base dati.*

## 4.5. Documentazione dello schema logico

Di seguito si riporta una rappresentazione grafica dello schema logico.

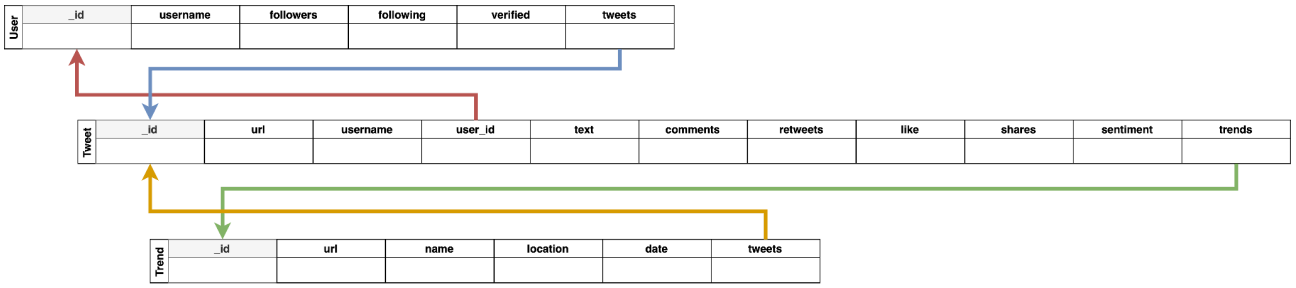

# 5. Script Creazione e Popolamento Database

## 5.1. Creazione dello schema

***NOTA***: Nello schema precedente gli id sono stati presentati come ObjectId, tuttavia nella base dati sono ObjectId salvati come stringa per via della modalità di collezionamento dei dati da Twitter che li ha trascritti in quel modo.

*Per la creazione delle collezioni del database si è deciso di utilizzare un JSON schema. Si tratta di un vocabolario che consente di annotare e validare documenti JSON. La creazione dello schema e degli indici è riportata nel file createSchema.js.*

```
db = connect("localhost:27017")

// create database Twitter
db = db.getSiblingDB('Twitter')

// drop all the collections
db.dropDatabase()

// create the collections

// create collection 'Users'
db.createCollection('Users', {
   validator: {
       $jsonSchema: {
           bsonType: "object",
           title: "Users object validation",
           required: ["_id", "username", "verified", "following", "followers"],
           properties: {
               username: {
                   bsonType: "string",
                   description: "Username of the user. Required.",
               },
               verified: {
                   bsonType: "bool",
                   description: "Whether the user is verified or not. Required.",
               },
               following: {
                   bsonType: "int",
                   description: "Number of users the user is following. Required. It must
be greater than or equal to 0.",
                   minimum: 0,
               },
               followers: {
```

```
                    bsonType: "int",
                    description: "Number of users following the user. Required. It must be
greater than or equal to 0.",
                    minimum: 0,
                }
            }
        }
    }
})
print("Users' schema created.")

// create collection 'Trends'
db.createCollection('Trends', {
    validator: {
        $jsonSchema: {
            bsonType: "object",
            required: ["_id", "url", "name", "location"],
            properties: {
                url: {
                    bsonType: "string",
                    description: "URL of the trend. Required.",
                },
                name: {
                    bsonType: "string",
                    description: "Name of the trend. Required.",
                },
                location: {
                    bsonType: "string",
                    description: "Location of the trend. Required.",
                }
            }
        }
    }
})

print("Trends' schema created.")

// create collection 'Tweets'
db.createCollection('Tweets', {
    validator: {
        $jsonSchema: {
            bsonType: "object",
            required: ["_id", "url", "username", "text", "retweets", "likes", "shares",
"sentiment"],
            properties: {
                url: {
```

```
                bsonType: "string",
                description: "URL of the tweet. Required.",
            },
            username: {
                bsonType: "string",
                description: "Username of the user who tweeted. Required.",
            },
            text: {
                bsonType: "string",
                description: "Text of the tweet. Required.",
            },
            retweets: {
                bsonType: "int",
                description: "Number of retweets. Required. It must be greater than or
equal to 0.",
                minimum: 0,
            },
            likes: {
                bsonType: "int",
                description: "Number of likes. Required. It must be greater than or
equal to 0.",
                minimum: 0,
            },
            shares: {
                bsonType: "int",
                description: "Number of shares. Required. It must be greater than or
equal to 0.",
                minimum: 0,
            },
            sentiment: {
                bsonType: "double",
                description: "Sentiment of the tweet. Required.",
            }
        }
    }
  }
})
print("Tweets' schema created.")
```

*Si è deciso di creare poi due indici per velocizzare le operazioni frequenti su data, nome e luogo di un trend e sull'username di un utente.*

```
// create index for 'Trends' on 'name', 'date', 'location' and rename to
name_date_location
db.Trends.createIndex({ name: 1, date: 1, location: 1 }, {unique : true, name :
"name_date_location_index"})
```

```
print("Index created for Trends.")

// create index for 'Users' on 'username'
db.Users.createIndex({ username: 1 }, {unique : true, name : "username_index"})
print("Index created for Users.")
```

*Per gli altri eventuali campi non definiti nello schema, non è presente una validazione perché si è ritenuto potessero anche avere formati diversi.*

## 5.2. Popolamento del database

Per il popolamento del database si è deciso di utilizzare uno script python (*loadData.py*) che si occupa di prendere i dati da file in formato JSON e caricarli nelle collezioni opportune. Per la sua esecuzione è richiesta la previa installazione di *pymongo*.

```
try:
   import pymongo
except ImportError:
   print("pymongo is not installed. Please install it using 'pip install pymongo'")
   exit(1)

import json, os

client = pymongo.MongoClient("mongodb://localhost:27017/")

db = client["Twitter"]

# read the json file from data/trends/*.json and insert them into the database in the collection "Trends"
for filename in os.listdir("database/data/trends"):
   if filename.endswith(".json"):
       with open("database/data/trends/" + filename, "r") as f:
           data = json.load(f)
           db["Trends"].insert_many(data)
           print("Inserted", len(data), "documents into the collection 'Trends'")

# read the json file from data/tweets/*.json and insert them into the database in the collection "Tweets"
for filename in os.listdir("database/data/tweets"):
   if filename.endswith(".json"):
       with open("database/data/tweets/" + filename, "r") as f:
           data = json.load(f)
           db["Tweets"].insert_many(data)
           print("Inserted", len(data), "documents into the collection 'Tweets'")
```

```
# read the json file from data/users/*.json and insert them into the database in the collection "Users"
for filename in os.listdir("database/data/users"):
    if filename.endswith(".json"):
        with open("database/data/users/" + filename, "r") as f:
            data = json.load(f)
            db["Users"].insert_many(data)
            print("Inserted", len(data), "documents into the collection 'Users'")

print("Done")
```

## 5.3. Operazioni di inserimento

Si riporta di seguito l'esempio di operazione di inserimento nella collezione *Trend* presente nel file *create.js*.

```
function createTrend(db, trend) {
    if (db.Trends.findOne({ _id: trend._id }) != null) {
        return 1
    } else {
        db.Trends.insertOne(trend)
        return 0
    }
}
```

Lo script controlla prima che il trend che si intende inserire non sia già presente e, se non lo è, viene inserito, altrimenti viene stampato un messaggio di errore.

Si riporta di seguito l'esempio di operazione di inserimento nella collezione *User* presente nel file *create.js*.

```
function createUser(db, user) {
    if (db.Users.findOne({ _id: user._id }) != null) {
        return 1
    } else {
        db.Users.insertOne(user)
        return 0
    }
}
```

Lo script controlla che l'utente non esista già e, se non esiste, lo inserisce.

Si riporta di seguito l'esempio di operazione di inserimento nella collezione *Tweet* presente nel file *create.js*.

```
function createTweet(db, tweet) {

    const trends = db.Trends.find({ _id: { $in: tweet.trends } }).toArray()
```

```
    const user = db.Users.findOne({ _id: tweet.user_id })

    if (trends.length != tweet.trends.length) {
        return 1
    }

    if (user == null) {
        return 1
    }

    db.Tweets.insertOne(tweet)

    db.Users.updateOne(
        { _id: user._id },
        { $push: { tweets: tweet._id } }
    )

    db.Trends.updateMany(
        { _id: { $in: tweet.trends } },
        { $push: { tweets: tweet._id } }
    )

    return 0

}
```

Un tweet viene inserito se esiste il trend a cui afferisce se esiste l'utente che lo ha scritto.

## 5.4. Operazioni di lettura

Si riporta di seguito l'esempio di operazione di lettura dei trend di un tweet presente nel file *read.js*.

```
function getTrendsByTweet(db, tweet_id) {
    var tweet = db.Tweets.findOne({_id: tweet_id});
    if (tweet == null) {
        return 1;
    }
    trends_id = tweet.trends;
    if (trends_id == null) {
        return 1;
    }
    trends = [];
    trends_id.forEach(trend_id => {
        trend = db.Trends.findOne({_id: trend_id});
        if (trend == null) {
```

```
            return 1;
        }
        trends.push(trend);
    });
    return trends;
}
```

Si riporta di seguito l'esempio di operazione di lettura dei tweet di un trend presente nel file *read.js*.

```
function getTweetsByTrend(db, trend_id) {
    var trend = db.Trends.findOne({_id: trend_id});
    if (trend == null) {
        return 1;
    }
    tweets_id = trend.tweets;
    if (tweets_id == null) {
        return 1;
    }
    tweets = [];
    tweets_id.forEach(tweet_id => {
        tweet = db.Tweets.findOne({_id: tweet_id});
        if (tweet == null) {
            return 1;
        }
        tweets.push(tweet);
    });
    return tweets;
}
```

Si riporta di seguito l'esempio di operazione di lettura dei tweet di un utente presente nel file *read.js*.

```
function getTweetsByUser(db, user_id) {
    var user = db.Users.findOne({_id: user_id});
    if (user == null) {
        return 1;
    }
    tweets_id = user.tweets;
    if (tweets_id == null) {
        return 1;
    }
    tweets = [];
    tweets_id.forEach(tweet_id => {
        tweet = db.Tweets.findOne({_id: tweet_id});
        if (tweet == null) {
            return 1;
```

```
        }
        tweets.push(tweet);
    });
    return tweets;
}
```

Si riporta di seguito l'esempio di operazione di lettura dell'utente di un tweet presente nel file *read.js*.

```
function getUserByTweet(db, tweet_id) {
    var tweet = db.Tweets.findOne({_id: tweet_id});
    if (tweet == null) {
        return 1;
    }
    user_id = tweet.user_id;
    if (user_id == null) {
        return 1;
    }
    user = db.Users.findOne({_id: user_id});
    if (user == null) {
        return 1;
    }
    return user;
}
```

Si riporta di seguito l'esempio di operazione di lettura dei commenti di un tweet presente nel file *read.js*.

```
function getCommentsByTweet(db, tweet_id) {
    var tweet = db.Tweets.findOne({_id: tweet_id});
    if (tweet == null) {
        return 1;
    }
    comments = tweet.comments;
    if (comments == null) {
        return 1;
    }
    return comments;
}
```

## 5.5. Operazioni di aggiornamento

Si riporta di seguito l'esempio di operazione di aggiornamento nella collezione *Tweet* presente nel file *update.js*.

```
function updateTweet(db, tweet_id, ...params) {
```

```
    tweet = db.Tweets.findOne({ _id: tweet_id })

    if (tweet == null) {

        return 1

    } else {

        params.forEach(param => {

            // params contains a dictionary with the key being the field to update and the
value being the new value
            // e.g. { text: "new text" }
            db.Tweets.updateOne(
                { _id: tweet_id },
                { $set: param }
            )

        })

    }

    return 0

}
```

Tale script effettua l'aggiornamento del numero di likes e di shares del tweet, se esso esiste.

Si riporta di seguito l'esempio di operazione di aggiornamento nella collezione *Trend* presente nel file *update.js*.

```
function updateTrend(db, trend_id, ...params) {

    trend = db.Trends.findOne({ _id: trend_id })

    if (trend == null) {

        return 1

    } else {

        params.forEach(param => {

            // params contains a dictionary with the key being the field to update and the
value being the new value
            // e.g. { name: "new name" }
            db.Trends.updateOne(
```

```
                { _id: trend_id },
                { $set: param }
            )

        })

    }

    return 0

}
```

In questo script se il trend esiste, ne viene aggiornata la data a quella attuale.

Si riporta di seguito l'esempio di operazione di aggiornamento nella collezione *User* presente nel file *update.js*.

```
function updateUser(db, user_id, ...params) {

    user = db.Users.findOne({ _id: user_id })

    if (user == null) {

        return 1

    } else {

        params.forEach(param => {

            // params contains a dictionary with the key being the field to update and the
value being the new value
            // e.g. { name: "new name" }
            db.Users.updateOne(
                { _id: user_id },
                { $set: param }
            )

        })

    }

    return 0

}
```

In questo script, se l'utente esiste, ne viene aggiornata la biografia.

## 5.6. Operazioni di rimozione

Si riporta di seguito l'esempio di operazione di rimozione dalla collezione *User* presente nel file *delete.js*.

```
function deleteUser(user_id) {

   user = db.Users.findOne({ _id: user_id })

   if (user == null) {

       return 1

   } else {

       if (user.tweets == null) {

           return 1

       } else {

           user.tweets.forEach(tweet_id => {

               tweets = db.Tweets.find({ _id: tweet_id })

               tweets.forEach(tweet => {

                   tweet.trends.forEach(trend_id => {
                       db.Trends.updateOne(
                           { _id: trend_id },
                           { $pull: { tweets: tweet._id } }
                       )
                   })

                   db.Tweets.deleteOne(
                       { _id: tweet._id }
                   )
               })

           })
       }

   }

   db.Users.deleteOne(
```

```
        { username: user.username }
    )

    return 0

}
```

Se l'utente esiste e ha scritto dei tweet, essi vengono cancellati dalla collezione Tweet e ne viene rimosso il riferimento dai rispettivi trend a cui afferiscono. Infine viene rimosso l'utente.

Si riporta di seguito l'esempio di operazione di rimozione dalla collezione *Tweet* presente nel file *delete.js*.

```
function deleteTweet(tweet_id) {

    tweet = db.Tweets.findOne({ _id: tweet_id })

    if (tweet == null) {

        return 1

    } else {

         // find the user who wrote the tweet and remove the id of this tweet from his/her
tweets array
        db.Users.updateOne(
            { _id: tweet.user_id },
            { $pull: { tweets: tweet._id } }
        )

        tweet.trends.forEach(trend => {
             // find the trend related to the tweet and remove the id of this tweet from
its tweets array
            db.Trends.updateOne(
                { _id: trend },
                { $pull: { tweets: tweet._id } }
            )
        })

        db.Tweets.deleteOne(
            { _id: tweet._id }
        )

        return 0

    }
```

```
}
```

Per la rimozione del tweet, se esso esiste, se ne rimuove il riferimento sia dal trend a cui afferisce, che dall'utente che lo ha scritto e poi si effettua la rimozione.

Si riporta di seguito l'esempio di operazione di rimozione dalla collezione *Trend* presente nel file *delete.js*.

```
function deleteTrend(trend_id) {

    trend = db.Trends.findOne({ _id: trend_id })

    if (trend == null) {

        return 1

    } else {

        if (trend.tweets == null) {

            return 1

        } else {

            trend.tweets.forEach(tweet_id => {

                tweets = db.Tweets.find({ _id: tweet_id })

                tweets.forEach(tweet => {
                    db.Users.updateOne(
                        { _id: tweet.user_id },
                        { $pull: { tweets: tweet._id } }
                    )
                })

                db.Tweets.deleteOne(
                    { _id: tweet_id }
                )

            })

        }

        db.Trends.deleteOne({ _id: trend_id })

        return 0
```

```
    }

}
```

Se il trend che si intende cancellare esiste nella collezione, allora si prendono tutti i tweet che vi fanno riferimento, si rimuove il loro riferimento dall'array dei tweet degli utenti che li hanno scritti e si cancellano. Infine si cancella il trend.

# 6. Query

## 6.1. Aggregation: Average sentiment per Trend

*Per ogni trend, selezionare tutti i tweet associati al trend e mostrare il sentiment ottenuto come media dei sentiment dei tweet selezionati. La query si trova nel file Operation1.js.*

```
function operation1(db) {

    trends = db.getCollection('Trends').find({});

    results = [];

    trends.forEach(function (trend) {

        result = db.getCollection('Trends').aggregate([
            {
                $match: {
                    name: trend.name,
                    location: trend.location,
                    date: trend.date
                }
            }, {
                $unwind: {
                    path: '$tweets'
                }
            }, {
                $lookup: {
                    from: 'Tweets',
                    localField: 'tweets',
                    foreignField: '_id',
                    as: 'tweetsData'
                }
            }, {
                $unwind: {
                    path: '$tweetsData'
```

```
                }
            }, {
                $group: {
                    _id: {
                        name: '$name',
                        location: '$location',
                        date: '$date'
                    },
                    sentiment: {
                        $avg: '$tweetsData.sentiment'
                    }
                }
            }, {
                $project: {
                    _id: 0,
                    name: '$_id.name',
                    location: '$_id.location',
                    date: '$_id.date',
                    sentiment: 1
                }
            }
        ]);

        results.push(result.toArray()[0]);

    });

    return results;

}
```

## 6.2. Aggregation: Sentiment percentages

*Per ogni trend, selezionare tutti i tweet che vi afferiscono e, per ogni categoria di sentiment che il tweet può assumere, stampare la percentuale di tweet che hanno ottenuto quel determinato sentiment. La query si trova nel file Operation2.js.*

```
function operation2(db) {

    trends = db.getCollection('Trends').find({});

    results = [];

    trends.forEach(function (trend) {
        result = db.getCollection('Trends').aggregate(
            [
```

```
{
    $match: {
        name: trend.name,
        location: trend.location,
        date: trend.date
    }
}, {
    $unwind: {
        path: '$tweets'
    }
}, {
    $lookup: {
        from: 'Tweets',
        localField: 'tweets',
        foreignField: '_id',
        as: 'tweetsData'
    }
}, {
    $unwind: {
        path: '$tweetsData'
    }
}, {
    $group: {
        _id: '$_id',
        totalTweets: {
            $sum: 1
        },
        positiveTweets: {
            $sum: {
                $cond: [
                    {
                        $gt: [
                            '$tweetsData.sentiment', 0.2
                        ]
                    }, 1, 0
                ]
            }
        },
        neutralTweets: {
            $sum: {
                $cond: [
                    {
                        $and: [
                            {
                                $gte: [
                                    '$tweetsData.sentiment', -0.2
```

```
                                ]
                            }, {
                                $lte: [
                                    '$tweetsData.sentiment', 0.2
                                ]
                            }
                        ]
                    }, 1, 0
                ]
            }
        },
        negativeTweets: {
            $sum: {
                $cond: [
                    {
                        $lt: [
                            '$tweetsData.sentiment', -0.2
                        ]
                    }, 1, 0
                ]
            }
        }
    }
}, {
    $project: {
        totalTweets: 1,
        positivePercentage: {
            $multiply: [
                {
                    $divide: [
                        '$positiveTweets', '$totalTweets'
                    ]
                }, 100
            ]
        },
        neutralPercentage: {
            $multiply: [
                {
                    $divide: [
                        '$neutralTweets', '$totalTweets'
                    ]
                }, 100
            ]
        },
        negativePercentage: {
            $multiply: [
```

```
                                {
                                    $divide: [
                                        '$negativeTweets', '$totalTweets'
                                    ]
                                }, 100
                            ]
                        }
                    }
                }, {
                    $project: {
                        _id: 0,
                        name: trend.name,
                        location: trend.location,
                        date: trend.date,
                        positivePercentage: 1,
                        neutralPercentage: 1,
                        negativePercentage: 1
                    }
                }
            ]
        );

        results.push(result.toArray()[0]);

    });

    return results;

}
```

## 6.3. Aggregation: Trend diffusion degree

*Dato un certo trend, identificare tutti gli utenti che hanno pubblicato tweet che vi afferiscono e sulla base del loro numero di followers identificare quante persone sono state all'incirca raggiunte dal trend per ognuno di quei tweet, come somma del numero di followers. La query si trova nel file Operation3.js.*

```
function operation3(db, trendName, trendLocation, trendDate) {

    var trend = db.getCollection("Trends").findOne({
        name: trendName,
        location: trendLocation,
        date: trendDate
    });

    if (!trend) {
```

```
        return {
            error: "Trend not found"
        };
    }

    var tweetIds = trend.tweets;

    var comments = db.getCollection("Tweets").aggregate([
        {
            $match: {
                _id: {
                    $in: tweetIds
                }
            }
        },
        {
            $unwind: {
                path: '$comments'
            }
        }

    ]).toArray();

    ids = {};

    comments.forEach(element => {
        comment_user_id = element.comments.user_id;
        // if the user with tweet_user_id is in the Users collection, then add it to the
ids
        // if the user with comment_user_id is in the Users collection, then add it to the
ids
        user = db.getCollection("Users").findOne({ _id: comment_user_id });
        if (user) {
            ids[comment_user_id] = user.followers;
        }
    });

    tweetIds.forEach(element => {
        tweet_user_id = db.getCollection("Tweets").findOne({ _id: element }).user_id;
        user = db.getCollection("Users").findOne({ _id: tweet_user_id });
        if (user) {
            ids[tweet_user_id] = user.followers;
        }
    });

    var sum = 0;
```

```
    for (var key in ids) {
        sum += ids[key];
    }

    return {
        trendName: trendName,
        trendLocation: trendLocation,
        trendDate: trendDate,
        diffusionDegree: sum
    };
}
```

## 6.4. Aggregation: User coherence score

*Per ogni utente, raggruppare i tweet che ha scritto per topic e, per ogni cluster, assegnare all'utente un punteggio di coerenza, fare la media dei punteggi ottenuti. La query si trova nel file Operation4.js.*

```
function operation4() {

    userScore = {};

    var users = db.getCollection('Users').find({});

    users.forEach(user => {

        // get all the tweets written by the user
        tweets = db.getCollection('Tweets').find({ user_id: user._id });

        // group the tweets by trends
        tweetsByTrend = {};
        tweets.forEach(tweet => {
            var trends = tweet.trends;
            trends.forEach(trend => {
                if (tweetsByTrend[trend]) {
                    tweetsByTrend[trend].push(tweet);
                } else {
                    tweetsByTrend[trend] = [tweet];
                }
            });
        });

        // for each trend, calculate the coherence score
        var scores = {};
        for (var trend in tweetsByTrend) {
            tweets = tweetsByTrend[trend];
```

```
            var sum = 0;
            tweets.forEach(tweet => {
                sum += tweet.sentiment;
            });
            avg = tweets.length > 0 ? sum / tweets.length : 0;
            scores[trend] = avg;
        }

        // average the scores obtained
        var sum = 0;
        for (var key in scores) {
            sum += scores[key];
        }

        userScore[user.username] = Object.values(scores).length > 0 ? sum /
Object.values(scores).length : 0;

    });

    // min max normalization of the scores
    var min = Math.min(...Object.values(userScore));
    var max = Math.max(...Object.values(userScore));
    for (var key in userScore) {
        userScore[key] = (userScore[key] - min) / (max - min) * 100;
    }

    return userScore;

}
```

## 6.5. Aggregation: User's sentiment percentages

*Dato un utente, prendi i tweet che ha scritto e calcola le percentuali di tweet con sentiment positivo, negativo e neutro. La query si trova nel file Operation5.js.*

```
function operation5(db, username) {

    result = db.getCollection("Users").aggregate([

        {
            $match: {
                username: username
            }
        },
        {
            $lookup: {
                from: "Tweets",
```

```
                localField: "tweets",
                foreignField: "_id",
                as: "userTweets"
            }
        },
        {
            $unwind: "$userTweets"
        },
        {
            $group: {
                _id: "$_id",
                userTweets: { $push: "$userTweets" },
                positiveTweets: { $sum: { $cond: [{ $gt: ['$userTweets.sentiment', 0.2] }, 1, 0] } },
                neutralTweets: {
                    $sum: {
                        $cond: [{
                            $and: [{
                                $gte: [
                                    '$userTweets.sentiment', -0.2
                                ]
                            }, {
                                $lte: [
                                    '$userTweets.sentiment', 0.2
                                ]
                            }
                            ]
                        }, 1, 0]
                    }
                },
                negativeTweets: { $sum: { $cond: [{ $lt: ['$userTweets.sentiment', -0.2] }, 1, 0] } },
                totTweets: { $sum: 1 }
            }
        },
        // compute the percentages and return the precentages and the usename
        {
            $project: {
                _id: 0,
                username: username,
                positivePercentage: { $multiply: [{ $divide: ['$positiveTweets', '$totTweets'] }, 100] },
                neutralPercentage: { $multiply: [{ $divide: ['$neutralTweets', '$totTweets'] }, 100] },
                negativePercentage: { $multiply: [{ $divide: ['$negativeTweets', '$totTweets'] }, 100] }
```

```
            }
        }
    ])

    return result.Array()[0]

}
```

## 6.6. Aggregation: Engagement metrics computation

*Per ogni trend calcolare il numero medio di like, condivisioni e retweet che i suoi post hanno avuto. Incollare lo script per la query. La query si trova nel file Operation6.js.*

```
function operation6(db) {

    result = db.getCollection("Trends").aggregate([
        {
            $unwind: {
                path: '$tweets'
            }
        }, {
            $lookup: {
                from: 'Tweets',
                localField: 'tweets',
                foreignField: '_id',
                as: 'tweetsData'
            }
        }, {
            $unwind: {
                path: '$tweetsData'
            }
        },
        {
            $group: {
                _id: '$_id',
                name: {
                    '$first': '$name'
                },
                location: {
                    '$first': '$location'
                },
                date: {
                    '$first': '$date'
                },
                avgLikes: {
                    '$avg': '$tweetsData.likes'
```

```
                },
                avgShares: {
                    '$avg': '$tweetsData.shares'
                },
                avgRetweets: {
                    '$avg': '$tweetsData.retweets'
                }
            }
        }, {
            $project: {
                _id: 0,
                name: 1,
                location: 1,
                date: 1,
                avgLikes: 1,
                avgShares: 1,
                avgRetweets: 1
            }
        }
    ])

    res = []
    result.toArray().forEach(function (trend) {
        res.push(trend)
    })
    return res
}
```

## 6.7. Aggregation: Discussions' detection

*Dato un trend, per ogni tweet ad esso associato, verificare se i suoi commenti hanno dato origine a una discussione identificando eventuali sentiment discordanti. La query si trova nel file Operation7.js.*

```
function operation7(db, trendName, trendLocation, trendDate) {

    result = db.getCollection("Trends").aggregate([
        {
            $match: {
                name: trendName,
                location: trendLocation,
                date: trendDate
            }
        },
        {
```

```
        $unwind: {
            path: '$tweets'
        }
    },
    {
        $lookup: {
            from: 'Tweets',
            localField: 'tweets',
            foreignField: '_id',
            as: 'tweetsData'
        }
    },
    {
        $unwind: {
            path: '$tweetsData'
        }
    },
    // take the tweet and classify its sentiment as
    // positive if sentiment > 0.2
    // negative if sentiment < -0.2
    // neutral otherwise
    // then for each tweet take the comments and classify their sentiment
    // if the tweet as at least one comment with a different sentiment classification
    // then a discussion took place
    {
        $project: {
            _id: 0,
            tweetText: '$tweetsData.text',
            tweet: {
                $cond: {
                    if: {
                        $gt: ['$tweetsData.sentiment', 0.2]
                    },
                    then: 'positive',
                    else: {
                        $cond: {
                            if: {
                                $lt: ['$tweetsData.sentiment', -0.2]
                            },
                            then: 'negative',
                            else: 'neutral'
                        }
                    }
                }
            },
            comments: {
```

```
                $map: {
                    input: '$tweetsData.comments',
                    as: 'comment',
                    in: {
                        $cond: {
                            if: {
                                $gt: ['$$comment.sentiment', 0.2]
                            },
                            then: 'positive',
                            else: {
                                $cond: {
                                    if: {
                                        $lt: ['$$comment.sentiment', -0.2]
                                    },
                                    then: 'negative',
                                    else: 'neutral'
                                }
                            }
                        }
                    }
                }
            }
        }
    },
    {
        $project: {
            _id: 0,
            tweet: 1,
            comments: 1,
            tweetText: 1,
            // if the tweet's comments array is not null
            // then check if the tweet's sentiment is different from
            // the comments' sentiment
            // if so then a discussion took place
            discussion: {
                $cond: {
                    if: {
                        $ne: ['$comments', null]
                    },
                    then: {
                        //count the number of comments with a different sentiment
                        $gt: [
                            {
                                $size: {
                                    $filter: {
                                        input: '$comments',
```

```
                                        as: 'comment',
                                        cond: {
                                            $ne: ['$$comment', '$tweet']
                                        }
                                    }
                                }
                            },
                            0
                        ]
                    },
                    else: false
                }
            }

        }
    }, {
        $project: {
            _id: 0,
            tweet: 1,
            tweetText: 1,
            comments: 1,
            discussion: {
                $cond: {
                    if: '$discussion',
                    then: true,
                    else: false
                }
            }
        }
    }
])

res = []
result.toArray().forEach(element => {
    res.push({
        tweetText: element.tweetText,
        discussion: element.discussion
    })
});
return res;
}
```

## 6.8. Altre query

### 6.8.1. Utente da più tempo su Twitter

Ottieni l'utente che si trova da più tempo su Twitter.

```
function getEldestUser(db){

   users = db.Users.find({}).sort({"joined_date": 1}).toArray()
   users.sort(function (a, b) {
       return a.age - b.age
   })

   return {username: users[0].username, joined_date: users[0].joined_date}

}
```

### 6.8.2. Tweet più condivisi

Ottieni i tweets più condivisi.

```
function getMostSharedTweets(db, k){

   tweets = db.Tweets.find({}).sort({shares: -1}).limit(k).toArray()

   tweets.sort(function (a, b) {
       return b.shares - a.shares
   })

   res = []

   for (tweet in tweets) {
       res.push({text: tweets[tweet].text, shares: tweets[tweet].shares})
   }

   return res

}
```

### 6.8.3. Trends più popolari

Ottieni i trend più popolari.

```
function getPopularTrends(db, minTweets){

   trends = db.Trends.find({}).toArray()
```

```
    trends.sort(function (a, b) {
        return b.tweets.length - a.tweets.length
    })

    trends = trends.filter(function (trend) {
        return trend.tweets.length > minTweets
    })

    res = []

    trends.map(function (trend) {
           return {name: trend.name, location: trend.location, date: trend.date, tweets:
trend.tweets.length}
    })

    for (trend in trends) {
              res.push({name: trends[trend].name, location: trends[trend].location, date:
trends[trend].date, tweets: trends[trend].tweets.length})
    }

    return res.slice(0, minTweets)

}
```

### 6.8.4. Utenti più popolari

Ottieni i tweet più popolari.

```
function getPopularUsers(db, minFollowers){

    users = db.Users.find({}).sort({"followers": -1}).toArray()

    users = users.filter(function (user) {
        return user.followers > minFollowers
    })

    users.map(function (user) {
                return {username: user.username, followers: user.followers, tweets:
user.tweets.length}
    })

    res = []

    for (user in users) {
              res.push({username: users[user].username, followers: users[user].followers,
tweets: users[user].tweets.length})
```

```
    }

    return res

}
```